



浙江大學
ZHEJIANG UNIVERSITY

人工智能算法与系统-2024 秋

金融异常检测任务

姓名 刘京宗

学号 22451040

学院 软件学院

2024 年 10 月 21 日

1 背景

金融欺诈是一个持续存在的问题，随着数字金融的快速发展，反欺诈技术在互联网金融信贷业务中得到了广泛应用。近年来，图神经网络（GNN）作为神经网络的一个子领域，在反欺诈检测中发挥了重要作用。与传统方法相比，图神经网络能够有效捕捉金融社交网络中的复杂关联，从而更好地识别欺诈行为。

图神经网络（Graph Neural Networks, GNN）自 2009 年提出以来，已经发展出多个变种，包括 GraphSAGE、GAT 等，这些网络利用图结构数据学习节点之间的复杂依赖关系。在金融异常检测任务中，图神经网络可以处理如用户关联、交易网络等图结构数据，有效提高欺诈检测的精度。

2 实验介绍

2.1 实验目的

- 了解如何使用 PyTorch 进行神经网络训练。
- 掌握如何使用 PyTorch-Geometric 库设计图神经网络。
- 利用 MO 平台评估模型性能，关注节点异常检测任务的准确性。

2.2 实验环境

本实验在以下软件和库的环境下进行：

- Numpy = 1.26.4
- PyTorch = 2.3.1
- PyTorch-Geometric = 2.5.3
- Torch-Scatter = 2.1.2
- Torch-Sparse = 0.6.18

2.3 数据集信息

实验使用的 DGraph-Fin 数据集包含数百万个节点和边，反映了用户之间的社交关系。每个节点包含一个 20 维的特征向量，标签分为四类，其中类 0 代表正常用户，类 1 代表欺诈用户。本实验的目标是从中区分正常用户和欺诈用户。数据集还包含边的类型和时间戳信息。

3 算法原理

在图神经网络（Graph Neural Networks, GNN）中，算法的核心思想是通过邻居节点间的信息传播和特征聚合，逐步更新每个节点的特征表示，从而在复杂的图结构中进行有效的学习。与传统神经网络相比，GNN 不仅能处理节点的特征，还能利用图中节点与节点之间的连接关系（边）来丰富模型的表达能力。因此，图神经网络特别适用于那些天然包含图结构数据的问题，如社交网络分析、推荐系统、金融网络中的反欺诈检测等。

在本实验中，我们采用了经典的图神经网络算法，如 GraphSAGE 和 GAT，并基于这些方法结合多层感知机（MLP）进行节点分类任务。以下是这些算法的详细原理和实现步骤：

1. 信息传播机制（Message Passing Mechanism）图神经网络通过信息传播机制来处理图结构数据。在每一层中，节点的特征表示会从邻居节点接收信息，更新自身的表示。这个过程可以看作是通过图的拓扑结构对节点特征进行逐层的递归聚合。

2. 节点特征聚合（Node Feature Aggregation）在每一层中，每个节点的特征不仅仅依赖于自己的特征，还要通过聚合其邻居节点的特征来更新表示。这个聚合过程的设计决定了图神经网络的表达能力和应用场景。例如，GraphSAGE 通过均值、LSTM、池化等方式对邻居特征进行聚合，而 GAT 则通过注意力机制加权邻居特征。

3.1 GraphSAGE

GraphSAGE (Graph Sample and Aggregate) 是一种基于采样和聚合的图神经网络模型。该模型的关键思想是：- ** 邻居采样 **：在每一层中，只从每个节点的邻居集中随机采样一部分节点，而不是使用所有的邻居节点进行聚合。这种方法能够显著降低计算复杂度，适用于大规模图数据集。- ** 特征聚合 **：通过聚合每个节点的邻居节点特征更新该节点的特征表示。常见的聚合函数包括均值、池化（max pooling）以及 LSTM 等。

GraphSAGE 的数学公式如下：

$$h_v^k = \sigma \left(W^k \cdot \text{AGG} \left(h_v^{k-1}, \{h_u^{k-1}, u \in N(v)\} \right) \right)$$

其中：- h_v^k 是第 k 层节点 v 的特征表示；- $N(v)$ 表示节点 v 的邻居节点集合；- W^k 是第 k 层的权重矩阵；- AGG 是聚合函数，如均值或池化；- σ 是激活函数（如 ReLU）。

在实际应用中，GraphSAGE 可以动态扩展到大规模图结构，并且由于其采样策略，能够有效控制计算和内存的开销。

3.2 GAT (Graph Attention Network)

GAT (Graph Attention Network) 引入了自注意力机制，允许每个节点在更新自己的表示时，为不同的邻居节点分配不同的权重。与 GraphSAGE 的均值聚合不同，GAT 通过注意力系数决定了各个邻居节点的重要性。这种方法使得网络能够在复杂图结构中捕捉到更细粒度的邻居关系。

GAT 的核心思想是通过以下注意力机制来计算节点 v 和其邻居节点 u 之间的注意力系数：

$$\alpha_{vu} = \frac{\exp(\text{LeakyReLU}(a^T \cdot [Wh_v || Wh_u]))}{\sum_{k \in N(v)} \exp(\text{LeakyReLU}(a^T \cdot [Wh_v || Wh_k]))}$$

其中：- α_{vu} 是节点 v 和 u 之间的注意力系数；- a^T 是一个注意力向量；- W 是权重矩阵；- $[Wh_v || Wh_u]$ 表示节点 v 和 u 特征的拼接。

在更新节点表示时，GAT 采用如下方式：

$$h_v^k = \sigma \left(\sum_{u \in N(v)} \alpha_{vu} W h_u^{k-1} \right)$$

这里，节点 v 的特征表示是其所有邻居节点特征的加权和，权重由注意力系数 α_{vu} 决定。

GAT 的优势在于，它可以为每个节点自适应地分配邻居节点的权重，从而在复杂的图结构中捕捉更有意义的特征。

3.3 MLP 模型

在本实验中，除了采用经典的 GNN 模型外，还使用了简单的多层感知机 (MLP) 作为基准模型。MLP 通过线性变换和非线性激活函数（如 ReLU）处理输入特征，并通过最后一层的 softmax 函数对节点进行二分类。公式如下：

$$\text{MLP}(x) = \text{softmax}(W_2 \cdot \text{ReLU}(W_1 \cdot x + b_1) + b_2)$$

其中：- W_1 和 W_2 是权重矩阵；- b_1 和 b_2 是偏置项；- x 是输入特征。

尽管 MLP 不利用图的结构信息，仅通过节点的特征进行分类，但在某些简单任务中也能表现出一定的分类能力。相比之下，GNN 通过引入图结构信息，能够显著提升节点分类任务的性能。

4 总结



测试详情			
测试点	状态	时长	结果
测试模型表现	✓	3s	测试的AUC为 0.784.

确定

图 1: 实验结果

在 300 个 epoch 的训练后，模型在验证集上的 AUC 值达到了 0.784，表明模型在区分正常用户和欺诈用户方面表现良好。

本实验通过图神经网络进行金融异常检测，验证了图神经网络在处理大规模动态图中的有效性。实验结果表明，图神经网络在识别金融欺诈方面具有较大的潜力。